

Classificação de Gênero Musical com Redes Neurais Convolucionais Aplicadas a Mel Spectrograms

Francisco Leonel Ferreira dos Santos¹

¹Instituto Federal de Educação, Ciência e Tecnologia do Maranhão (IFMA)
Campus Caxias – Caxias, MA – Brasil

leonel.s@acad.ifma.edu.br

Abstract. *Music genre classification is a fundamental task in the Music Information Retrieval (MIR) field. This work investigates the use of Convolutional Neural Networks (CNNs) applied to Mel Spectrograms for automatic music genre classification using the GTZAN dataset, which contains 1,000 audio clips of 30 seconds distributed across 10 genres. Audio files are converted into visual representations (Mel Spectrograms) and used as input to a VGG-like CNN architecture with batch normalization and dropout regularization. Multiple training runs were conducted with different learning rates (0.1, 0.05, 0.025), and the best configuration used SGD with LR = 0.025, cosine annealing schedule and early stopping (patience = 60). Two runs with this configuration achieved 83% and 81% accuracy on the test set, with the variation attributed to stochastic training. The model correctly classified a real-world metal track with 70.5% confidence.*

Resumo. *A classificação de gênero musical é uma tarefa fundamental na área de Recuperação de Informação Musical (Music Information Retrieval – MIR). Este trabalho investiga o uso de Redes Neurais Convolucionais (CNNs) aplicadas a Mel Spectrograms para classificação automática de gênero musical, utilizando o dataset GTZAN, que contém 1.000 clipes de áudio de 30 segundos distribuídos entre 10 gêneros. Foram realizadas múltiplas execuções com diferentes taxas de aprendizado (0,1; 0,05; 0,025), sendo que a melhor configuração utilizou SGD com LR = 0,025, schedule cosseno e early stopping com paciência de 60 épocas. Duas execuções com essa configuração atingiram 83% e 81% de acurácia no conjunto de teste, com a variação atribuída à estocasticidade do treinamento. O modelo classificou corretamente uma faixa de metal real com 70,5% de confiança.*

1. Introdução

A classificação automática de gênero musical é relevante em sistemas de recomendação, organização de acervos digitais e plataformas de *streaming* [1]. Determinar o gênero a partir do conteúdo sonoro é desafiador: gêneros não possuem fronteiras rígidas e subgêneros compartilham características acústicas semelhantes. Este trabalho aborda a tarefa de **classificação multiclasse**, atribuindo cada clipe a um dos 10 gêneros do GTZAN. A abordagem converte sinais de áudio em Mel Spectrograms — representações visuais da distribuição de energia sonora ao longo do tempo, organizadas em uma escala de frequências que imita a percepção auditiva humana. Diferentemente de um espectrograma convencional, cuja escala de frequências é linear, o Mel Spectrogram utiliza a escala Mel,

de natureza logarítmica: nela, a diferença entre 500 Hz e 1.000 Hz é perceptualmente equivalente à diferença entre 10.000 Hz e 10.500 Hz, refletindo o fato de que o ouvido humano distingue variações em frequências baixas com muito mais sensibilidade do que em frequências altas. Essa representação transforma o problema de classificação de áudio em um problema de visão computacional, permitindo o uso direto de CNNs, que são motivadas pela capacidade de extrair hierarquias de *features* espaciais sem engenharia manual [2].

2. Apresentação do Dataset

O GTZAN [1] contém 1.000 clipes WAV de 30 segundos (999 válidos), 10 gêneros com 100 amostras cada (balanceado), 22.050 Hz, mono. Acesso: <https://www.kaggle.com/datasets/andradaolteanu/gtzan-dataset-music-genre-classification>. O formato de entrada é $X \in \mathbb{R}^{N \times C \times H \times W}$ ($N = 64$ amostras — o tamanho do batch —, $C = 3$ canais, $H = W = 128$). Divisão: **70% treino** (699), **15% validação** (150) e **15% teste** (150), com estratificação por classe e seed 42.

2.1. Análise Exploratória

A Figura 1 apresenta a forma de onda e o Mel Spectrogram de um clipe de blues. No Mel Spectrogram, o eixo X representa o tempo, o eixo Y representa a frequência em escala Mel (aproximadamente logarítmica), e a intensidade de cada cor indica o nível de energia presente naquela faixa de frequência em cada instante — cores mais quentes (amarelo/laranja) indicam maior energia, enquanto cores mais frias (roxo/preto) indicam menor energia. A escala Mel privilegia a resolução nas frequências mais baixas, de forma análoga à percepção auditiva humana.




Figura 1. Forma de onda e Mel Spectrogram de um clipe de blues.

A Figura 2 compara espectrogramas de cinco gêneros: o metal exibe alta energia em agudos em todo o clipe; o classical, variações dinâmicas suaves; o jazz, regiões de silêncio intercaladas com passagens complexas.




Figura 2. Mel Spectrograms de cinco gêneros. As diferenças de textura e distribuição de energia motivam o uso de CNNs para classificação.

2.2. Limitações do Dataset

O arquivo `jazz.00054.wav` está corrompido e foi descartado no pré-processamento, resultando em 999 amostras. O dataset apresenta variações de qualidade entre clipes e ambiguidade na categorização, especialmente entre rock, blues e country [1].

3. Trabalhos Relacionados

3.1. Conceitos Fundamentais

Os trabalhos desta área utilizam técnicas que convém contextualizar brevemente. **MFCCs** (Mel-Frequency Cepstral Coefficients) são características numéricas extraídas manualmente do áudio que resumem o timbre sonoro em um vetor compacto, sem necessidade de treinar uma rede neural. **SVM** (Support Vector Machine) é um algoritmo clássico que busca o hiperplano de maior margem para separar as classes; tende a generalizar bem em datasets pequenos. **XGBoost** combina múltiplas árvores de decisão e é eficiente com dados tabulares como os MFCCs. **Ensemble learning** é a estratégia de combinar múltiplos modelos — por votação ou média — para obter uma predição melhor do que qualquer modelo individualmente. **Segmentação em janelas** divide o áudio em trechos menores com sobreposição, multiplicando as amostras de treino e combinando as predições de cada trecho na decisão final. **Transfer learning** reutiliza um modelo pré-treinado em um grande dataset como ponto de partida para uma nova tarefa. **Data augmentation** cria variações artificiais dos dados de treino — como alteração de tom ou adição de ruído — para ampliar o dataset sem coletar novos exemplos.

3.2. Trabalhos no GTZAN

O trabalho fundacional de [1] foi o primeiro a propor um sistema automático de classificação de gênero musical, utilizando o próprio dataset GTZAN que criaram. A abordagem extraía características numéricas do áudio — como padrões de ritmo e timbre — e as utilizava para treinar um classificador estatístico simples. Apesar da abordagem rudimentar para os padrões atuais, obteve $\approx 61\%$ de acurácia e estabeleceu o GTZAN como referência para comparação de trabalhos futuros na área.

Em [3], os autores propuseram classificar gêneros musicais alimentando uma rede neural diretamente com o sinal de áudio bruto, sem nenhuma conversão prévia para imagem ou espectrograma. Para contornar a limitação de ter apenas 100 exemplos por gênero, dividiram cada música em trechos menores e trataram cada trecho como uma amostra independente, aumentando artificialmente o volume de dados. Ao final, combinaram as predições de todos os trechos de uma mesma música para chegar à decisão final, atingindo 80,93% de acurácia.

Em [4], foi conduzida uma comparação entre diferentes abordagens — redes convolucionais simples, a arquitetura VGG16 e o algoritmo XGBoost — utilizando tanto Mel Spectrograms quanto MFCCs como entrada. O estudo revelou que cortar as músicas em janelas de 3 segundos melhorou consideravelmente o desempenho das redes neurais. Surpreendentemente, o XGBoost alimentado com MFCCs superou as redes convolucionais, sugerindo que algoritmos clássicos ainda são competitivos quando o dataset é pequeno.

Em [5], os autores adotaram uma estratégia diferente: em vez de classificar a música como um todo, separaram a parte vocal da parte instrumental e treinaram modelos especializados para cada uma. As previsões individuais foram depois combinadas para a decisão final. Essa divisão permitiu que cada modelo se especializasse em padrões mais específicos, resultando em desempenho superior ao estado da arte no GTZAN.

Em [6], foi feita uma comparação direta entre um SVM com características extraídas manualmente e uma CNN treinada sobre Mel Spectrograms. Os resultados mostraram que o SVM superou a CNN, evidenciando que, em contextos com poucos dados, a escolha cuidadosa das características de entrada pode ser mais vantajosa do que o uso de redes profundas.

Em relação aos trabalhos citados, este trabalho implementa uma CNN *VGG-like* do zero, sem *transfer learning*, segmentação ou *data augmentation*, permitindo análise direta das limitações do modelo.

4. Método Implementado

4.1. Pré-processamento

Cada arquivo WAV é convertido em Mel Spectrogram via `librosa` (22.050 Hz, 128 bandas Mel). A amplitude é convertida para decibéis pela seguinte equação:

$$M_{dB}(t, m) = 10 \cdot \log_{10} \left(\frac{M(t, m)}{\max(M)} \right) \quad (1)$$

onde $M_{dB}(t, m)$ é a intensidade em decibéis na frequência m no instante de tempo t ; $M(t, m)$ é a energia bruta naquele ponto do espectrograma; $\max(M)$ é o valor máximo de energia em todo o espectrograma, utilizado como referência para que o pico sempre corresponda a 0 dB e todos os demais valores fiquem negativos, facilitando a comparação entre gravações com volumes diferentes; $\log_{10}$ é o logaritmo de base 10, que converte a escala de energia para uma escala perceptualmente próxima da audição humana; e o fator 10 é a constante que define a unidade decibel para medidas de energia — por convenção, 1 dB de energia equivale a $10 \cdot \log_{10}$ da razão entre dois valores de potência.

Os espectrogramas são salvos como PNG, redimensionados para 128×128 px e normalizados para $[0, 1]$. Os tensores são transferidos para a GPU em bloco, eliminando transferências por *batch*.

4.2. Arquitetura CNN

A arquitetura *VGG-like* possui 4 blocos convolucionais de profundidade crescente, seguidos de classificador denso:

$$\text{Entrada} \rightarrow \underbrace{B_1}_{64} \rightarrow \underbrace{B_2}_{128} \rightarrow \underbrace{B_3}_{256} \rightarrow \underbrace{B_4}_{512} \rightarrow \text{GAP} \rightarrow \text{FC}_{256} \rightarrow \text{FC}_{10}$$

Cada bloco B_i : $\text{Conv}(3 \times 3) \rightarrow \text{BN} \rightarrow \text{ReLU} \rightarrow \text{Conv}(3 \times 3) \rightarrow \text{BN} \rightarrow \text{ReLU} \rightarrow \text{MaxPool}(2 \times 2) \rightarrow \text{Dropout}(p_i)$, com $p_i \in \{0,2; 0,3; 0,4; 0,5\}$ crescendo com a profundidade. O GAP (Global Average Pooling) transforma os mapas de *features* para um vetor de 512 dimensões, independentemente do tamanho espacial da entrada. Em seguida, uma camada densa FC_{256} com 256 neurônios e ativação ReLU, seguida de Dropout (0,5), aprende combinações das *features* extraídas pelos blocos convolucionais. Por fim, a camada de saída FC_{10} produz 10 valores — um por gênero musical — cujas probabilidades são obtidas aplicando a função *softmax*, que converte os valores brutos em uma distribuição de probabilidade em que a classe com maior valor é a predição do modelo.

5. Configuração Experimental

Foram testados três valores de taxa de aprendizado mantendo os demais hiperparâmetros fixos. **LR = 0,1** convergiu rapidamente mas com oscilações severas na validação. **LR = 0,05** reduziu parcialmente as oscilações, com desempenho inferior. **LR = 0,025** apresentou o melhor equilíbrio entre estabilidade e acurácia, sendo selecionado como configuração definitiva. Duas execuções independentes com esse valor atingiram 83% e 81%, com a diferença atribuída à variabilidade estocástica do SGD. A Tabela 1 detalha os hiperparâmetros utilizados.

Tabela 1. Hiperparâmetros do experimento.

Hiperparâmetro	Valor
Otimizador	SGD
Taxa de aprendizado	0,025
Momentum	0,9
Weight decay	5×10^{-4}
Scheduler	CosineAnnealingLR
Épocas máximas	150
Early stopping (patience)	60
Batch size	64
Função de perda	CrossEntropyLoss
Label smoothing	0,1
Divisão treino/val/teste	70% / 15% / 15%
Seed	42

Ambiente: Python 3.10, PyTorch 2.x, librosa 0.10, Pillow, scikit-learn, seaborn, matplotlib, tqdm, kagglehub. Google Colab, GPU NVIDIA T4.

6. Resultados

Os resultados correspondem à execução com 81% de acurácia (melhor época: 75). A execução com 83% (melhor época: 129) é discutida na Seção 7.

6.1. Curvas de Treinamento

A Figura 3 evidencia oscilações consideráveis nas primeiras 50 épocas, seguidas de estabilização conforme o *CosineAnnealingLR* decai a taxa de aprendizado. A validação converge para 78–82% a partir da época 75, onde o *early stopping* salvou o melhor modelo.




Figura 3. Curvas de perda e acurácia (execução 81%). Linha verde: melhor época (75), selecionada pelo *early stopping*.

6.2. Métricas por Classe

As métricas utilizadas para avaliação são definidas como:

$$\text{Precisão} = \frac{VP}{VP + FP} \quad (2)$$

$$\text{Recall} = \frac{VP}{VP + FN} \quad (3)$$

$$F1 = 2 \cdot \frac{\text{Precisão} \times \text{Recall}}{\text{Precisão} + \text{Recall}} \quad (4)$$

$$\text{Acurácia} = \frac{VP + VN}{VP + VN + FP + FN} \quad (5)$$

onde VP são os verdadeiros positivos (predito corretamente como a classe), FP os falsos positivos (predito incorretamente como a classe), FN os falsos negativos (exemplos da classe que o modelo não identificou) e VN os verdadeiros negativos (corretamente classificados como outra classe). A Precisão mede a confiabilidade quando o modelo aponta uma classe; o Recall mede quantos exemplos reais de uma classe foram encontrados; o F1 é a média harmônica entre os dois; e a Acurácia mede o percentual de predições corretas no total.

A Tabela 2 apresenta os resultados no conjunto de teste. Jazz obteve *recall* perfeito (1,00) e rock o pior desempenho ($F1 = 0,45$), resultado consistente nas duas execuções realizadas.

Tabela 2. Resultados no conjunto de teste por gênero (execução 81%).

Gênero	Precisão	Recall	F1	N
blues	0,86	0,80	0,83	15
classical	0,93	0,93	0,93	15
country	0,74	0,93	0,82	15
disco	0,82	0,60	0,69	15
hiphop	0,80	0,80	0,80	15
jazz	0,88	1,00	0,94	15
metal	0,78	0,93	0,85	15
pop	0,68	0,87	0,76	15
reggae	0,87	0,87	0,87	15
rock	0,71	0,33	0,45	15
Acurácia		0,81		150
Macro avg	0,81	0,81	0,79	150

6.3. Matriz de Confusão

A Figura 4 apresenta a matriz de confusão no conjunto de teste. Linhas representam as classes reais e colunas as classes preditas.




Figura 4. Matriz de confusão no conjunto de teste. Linhas: classes reais; colunas: classes preditas.

6.4. Exemplos Visuais

A Figura 5 mostra exemplos de acertos e erros do modelo. Os erros revelam similaridade espectral entre disco/reggae e pop, e entre blues/pop e country.




Figura 5. Acertos (linha superior) e erros (linha inferior) do modelo.

Para verificar a generalização, foi testada a faixa *Awake and Alive* (Skillet), não presente no GTZAN, convertida para Mel Spectrogram com os mesmos parâmetros do pré-processamento. A Figura 6 apresenta o espectrograma gerado.




Figura 6. Mel Spectrogram de *Awake and Alive* (Skillet). Alta densidade de energia em frequências agudas é característica do metal.

O modelo predisse corretamente **metal** com 70,5% de confiança (disco em 2.º com 6,0%), demonstrando generalização além do conjunto de treinamento. A Figura 7 apresenta o ranking completo de probabilidades.




Figura 7. Ranking de probabilidades por gênero: metal predito com 70,5% de confiança.

7. Análise e Discussão

Gêneros bem classificados: jazz obteve *recall* perfeito ($F1 = 0,94$) em ambas as execuções — instrumentação acústica improvisada gera texturas espectrais altamente distintas. Classical ($F1 = 0,93$) destacou-se pela ausência de percussão eletrônica e dinâmica suave. Reggae ($0,87$) e country ($0,82$) tiveram bom desempenho com padrões rítmicos estáveis.

Gênero mais problemático: rock obteve $F1 = 0,45$ e *recall* de apenas $0,33$. A matriz de confusão evidencia dispersão em country (2), metal (2), pop (2), jazz (1) e reggae (1), refletindo a ampla diversidade estilística interna — resultado consistente nas duas execuções.

Variabilidade estocástica: As duas execuções com $LR = 0,025$ resultaram em 83% (época 129) e 81% (época 75). A diferença de 2 p.p. ilustra a variabilidade natural do SGD: a seed controla a inicialização dos pesos e a divisão dos dados, mas não a ordem exata dos *batches* em GPU, que introduz aleatoriedade residual.

Overfitting e seleção de LR: O gap treino ($\approx 100\%$) vs. validação ($\approx 80\%$) é esperado dado o tamanho reduzido do dataset. O *early stopping* com paciência de 60 épocas foi determinante para capturar o melhor modelo sem interrupção prematura. Taxas mais altas produziram oscilações severas e convergência para mínimos menos favoráveis; o *CosineAnnealingLR* permitiu refinamento independente do LR inicial.

8. Comparação com Trabalhos Relacionados

Os resultados obtidos (81–83%) são comparáveis à CNN 1D de [3] e ao cenário sem segmentação de [4], demonstrando que CNN 2D sobre Mel Spectrograms é competitiva mesmo sem *data augmentation* ou segmentação temporal. A diferença para o método de *ensemble* de [5] evidencia o potencial de ganho com estratégias de combinação de modelos.

Tabela 3. Comparação com trabalhos relacionados no GTZAN.

Trabalho	Modelo	Métrica	Resultado
[1]	Features + Gaussiano	Acurácia	$\approx 61\%$
[3]	CNN 1D (sinal bruto)	Acurácia	80,93%
[4]	CNN / VGG16 / XGBoost	Acurácia	até 83%
[5]	Ensemble + Atenção	Acurácia	estado da arte
[6]	SVM vs CNN	Acurácia	SVM > CNN
Este trabalho	CNN VGG-like	Acurácia	81–83%

9. Conclusão

Este trabalho investigou a classificação de gênero musical com CNNs sobre Mel Spectrograms no GTZAN. Após busca em $LR \in \{0,1; 0,05; 0,025\}$, a configuração com 0,025 mostrou-se a mais equilibrada. Duas execuções atingiram **81% e 83%** de acurácia, com variação atribuída à estocasticidade. Jazz obteve *recall* perfeito em ambas; rock permaneceu o mais difícil ($F1 \approx 0,45$). O modelo classificou corretamente uma faixa de metal real com 70,5% de confiança. Como trabalhos futuros: *data augmentation* e segmentação temporal [4]; *ensemble learning* [5]; múltiplas seeds para estimativa robusta do desempenho médio; e comparação com Transformers para áudio (AST).

Declaração de Uso de IA Generativa

Declaro que utilizei ferramenta de IA generativa (Claude, Anthropic) como apoio para estruturação do código-fonte, depuração e sugestão de comentários no notebook. O conteúdo foi revisado, adaptado e validado por mim. Assumo responsabilidade pela implementação, análise, resultados e texto final.

Referências

- [1] TZANETAKIS, G.; COOK, P. **Musical genre classification of audio signals**. IEEE Transactions on Speech and Audio Processing, v. 10, n. 5, p. 293–302, 2002.
- [2] GOODFELLOW, I.; BENGIO, Y.; COURVILLE, A. **Deep Learning**. Cambridge: MIT Press, 2016.
- [3] ALLAMY, S.; KOERICH, A. L. **1D CNN architectures for music genre classification**. arXiv:2105.07302, 2021. <https://arxiv.org/pdf/2105.07302>
- [4] MENG, Y. **Music genre classification: a comparative analysis of CNN and XGBoost approaches with mel-frequency cepstral coefficients and mel spectrograms**. arXiv:2401.04737, 2024. <https://arxiv.org/pdf/2401.04737>
- [5] LIU, Y.; DASGUPTA, A.; HE, Q. **Music genre classification: ensemble learning with subcomponents-level attention**. arXiv:2412.15602, 2024. <https://arxiv.org/pdf/2412.15602>
- [6] AKHTAR, R.; MISHRA, A. **Music genre classification using machine learning techniques**. arXiv:2509.01762, 2025. <https://arxiv.org/pdf/2509.01762v1>