



Classificação de Gênero Musical com CNNs Aplicadas a Mel Spectrograms

Dataset: GTZAN


Francisco Leonel Ferreira dos Santos

Professor: Rafael Torres Anchiêta

IFMA – Campus Caxias


Problema investigado

- ▶ Como classificar automaticamente o gênero musical a partir do conteúdo sonoro?
- ▶ Aplicações: recomendação, organização de acervos e plataformas de *streaming*.
- ▶ Desafio: gêneros possuem fronteiras subjetivas e características acústicas sobrepostas.
- ▶ Estratégia: converter áudio em Mel Spectrograms e tratar a tarefa como visão computacional.



Dataset

- ▶ **GTZAN**: 1.000 clipes WAV de 30 segundos.
- ▶ 10 gêneros, com 100 amostras por classe.
- ▶ Áudio mono, 22.050 Hz.
- ▶ 999 arquivos válidos: `jazz.00054.wav` descartado por corrupção.
- ▶ Divisão estratificada: 70% treino, 15% validação e 15% teste.



Diferenças de textura espectral entre gêneros motivam o uso de CNNs.

Conceitos fundamentais

Características e preparação

- ▶ **MFCCs**: características numéricas que resumem o timbre do áudio.
- ▶ **Segmentação**: divide o áudio em janelas menores com sobreposição.
- ▶ **Data augmentation**: cria variações artificiais dos dados de treino.

Modelos e estratégias

- ▶ **SVM**: busca o hiperplano de maior margem entre classes.
- ▶ **XGBoost**: combina árvores de decisão para dados tabulares.
- ▶ **Ensemble**: combina múltiplos modelos por média ou votação.
- ▶ **Transfer learning**: reutiliza um modelo pré-treinado.

Trabalhos relacionados

Trabalho	Abordagem	Resultado/ideia central
Tzanetakis e Cook (2002)	Features + classificador	$\approx 61\%$
Allamy e Koerich (2021)	CNN 1D no áudio bruto	80,93%
Meng (2024)	CNN, VGG16 e XGBoost	até 83%
Liu et al. (2024)	Ensemble + atenção	estado da arte
Akhtar e Mishra (2025)	SVM vs. CNN	SVM superou CNN

Posicionamento deste trabalho

CNN VGG-like treinada do zero sobre Mel Spectrograms, sem *transfer learning*, segmentação temporal ou *data augmentation*.

Modelo implementado

Pré-processamento

WAV $\rightarrow$ Mel Spectrogram com 128 bandas $\rightarrow$ PNG $\rightarrow$ redimensionamento para 128×128 px $\rightarrow$ normalização para $[0, 1]$.

Arquitetura CNN VGG-like

Entrada $\rightarrow B_1^{64} \rightarrow B_2^{128} \rightarrow B_3^{256} \rightarrow B_4^{512} \rightarrow \text{GAP} \rightarrow \text{FC}_{256} \rightarrow \text{FC}_{10}$


- ▶ Cada bloco: duas convoluções 3×3 , BatchNorm, ReLU, MaxPool e Dropout.
- ▶ Saída com 10 neurônios e *softmax*: uma probabilidade por gênero.

Configuração experimental

Hiperparâmetro	Valor
Otimizador	SGD
LR selecionado	0,025
Momentum	0,9
Weight decay	5×10^{-4}
Scheduler	CosineAnnealingLR
Épocas máximas	150
Early stopping	60
Batch size	64

- ▶ LRs testados: 0,1; 0,05; 0,025.
- ▶ LR 0,1: convergência rápida, mas validação instável.
- ▶ LR 0,05: reduziu oscilações, com desempenho inferior.
- ▶ LR 0,025: melhor equilíbrio entre estabilidade e acurácia.
- ▶ Ambiente: Google Colab com GPU NVIDIA T4.


Resultados obtidos



Melhor época da execução principal: 75.

- ▶ Execuções com LR 0,025 atingiram **83%** e **81%** de acurácia.
- ▶ Resultado reportado por classe: execução de 81% no teste.
- ▶ Melhores classes: jazz (F1 0,94), classical (0,93) e reggae (0,87).

Análise dos erros



- ▶ Rock foi o gênero mais difícil: F1 0,45 e recall 0,33.
- ▶ Erros de rock se dispersaram em country, metal, pop, jazz e reggae.
- ▶ Confusões refletem sobreposição acústica entre gêneros próximos.
- ▶ Também houve erros associados a similaridade espectral entre disco/reggae e pop.

Métricas de desempenho do modelo

Resumo no conjunto de teste

Métrica	Valor
Acurácia	0,81
Precisão macro	0,81
Recall macro	0,81
F1 macro	0,79
Amostras de teste	150


LR 0,025 obteve **81–83%** de acurácia em duas execuções independentes.

Leitura rápida

Precisão mede a confiabilidade da predição; recall mede quanto da classe real foi recuperado; F1 equilibra as duas medidas.

- ▶ Melhores F1: jazz 0,94; classical 0,93; reggae 0,87.
- ▶ Mais difícil: rock, com F1 0,45 e recall 0,33.
- ▶ Conseguiu bons resultados sem segmentação ou *data augmentation*.

Teste em um exemplo real



Distribuição das probabilidades da predição do modelo em um exemplo.

- ▶ Predição do modelo na música *Awake and Alive*.
- ▶ A predição do modelo na música como Metal.
- ▶ A música se categoriza como um dos sub gêneros de metal
- ▶ O modelo inferiu corretamente, com 70,5% de certeza, mesmo em uma música de mais de 30 segundos.
- ▶ Demonstra generalização em músicas reais.

Comparação com trabalhos relacionados

Trabalho	Modelo	Resultado
Tzanetakis e Cook (2002)	Features + Gaussiano	$\approx 61\%$
Allamy e Koerich (2021)	CNN 1D	80,93%
Meng (2024)	CNN / VGG16 / XGBoost	até 83%
Liu et al. (2024)	Ensemble + Atenção	estado da arte
Akhtar e Mishra (2025)	SVM vs. CNN	SVM > CNN
Este trabalho	CNN VGG-like	81–83%

Síntese

O desempenho é alto comparado com abordagens CNN no GTZAN, mesmo sem segmentação, aumento de dados ou ensembles.

Conclusões e trabalhos futuros

Conclusões

- ▶ Mel Spectrograms permitem aplicar CNNs à classificação musical.
- ▶ A CNN *VGG-like* atingiu 81–83% no GTZAN.
- ▶ Jazz e classical foram bem separados; rock permaneceu problemático.
- ▶ O teste com música real indicou capacidade de generalização.

Trabalhos futuros

- ▶ Aplicar *data augmentation*.
- ▶ Usar segmentação temporal.
- ▶ Avaliar ensembles e múltiplas seeds.
- ▶ Comparar com Transformers para áudio (AST).